Tarea 2+

Dalia Camacho

August 22, 2018

Para este ejemplo usaremos los datos de https://archive.ics.uci.edu/ml/machine-learning-databases/housing/. El objetivo es predecir el valor mediano de las viviendas en áreas del censo de Estados Unidos, utilizando variables relacionadas con criminalidad, ambiente, tipo de viviendas, etc.

Separa la muestra en dos partes: unos 400 para entrenamiento y el resto para prueba.

```
entrena <- sample(1:nrow(housing),400)

Base_entrena <- housing[entrena,]

Base_prueba <- housing[-entrena,]
```

Describe las variables en la muestra de prueba (rango, media, mediana, por ejemplo).

```
# Promedio
Prom <- colMeans(Base_prueba)</pre>
# Minimo
Min <- unlist(lapply(1:14, function(i){min(Base_prueba[,i])}))</pre>
# Máxiimo
Max <- unlist(lapply(1:14, function(i){max(Base_prueba[,i])}))</pre>
Mediana <- unlist(lapply(1:14, function(i){median(Base_prueba[,i])}))</pre>
# Tabla Resumen
matrix(c("Variable",c("CRIM", "ZN", "INDUS", "CHAS",
                       "NOX", "RM", "AGE", "DIS", "RAD",
                       "TAX", "PTRATIO", "B", "LSTAT", "MEDV"),
         "Promedio", Prom, "Mediana", Mediana,
         "Mínimo", Min, "Máximo", Max), byrow = FALSE, ncol = 5)
                                           [,3]
##
         [,1]
                     [,2]
                                                       [,4]
                                                                  [,5]
  [1,] "Variable" "Promedio"
                                           "Mediana" "Mínimo" "Máximo"
```

```
##
   [2,] "CRIM"
                    "1.78763403846154"
                                         "0.343255" "0.01096" "9.91655"
  [3,] "ZN"
                    "11.2307692307692"
                                         "0"
                                                    "0"
                                                               "85"
##
  [4,] "INDUS"
                                         "8.14"
                                                    "2.03"
##
                    "11.3663461538462"
                                                               "25.65"
## [5,] "CHAS"
                    "0.0769230769230769" "0"
                                                    "0"
                                                               "1"
##
   [6,] "NOX"
                    "0.559596153846154"
                                         "0.531"
                                                    "0.389"
                                                               "0.871"
## [7,] "RM"
                    "6.18269230769231"
                                         "6.1085"
                                                    "4.926"
                                                               "8.725"
## [8,] "AGE"
                                         "80.1"
                                                    "9.9"
                    "68.9538461538462"
                                                               "100"
                                                              "8.5353"
## [9,] "DIS"
                                                    "1.1691"
                    "4.00054038461538"
                                         "3.80355"
                                         "5"
## [10,] "RAD"
                    "7.94230769230769"
                                                    "1"
                                                               "24"
## [11,] "TAX"
                    "372.961538461538"
                                         "307"
                                                    "188"
                                                               "666"
## [12,] "PTRATIO"
                    "18.4230769230769"
                                         "18.95"
                                                    "13"
                                                               "21.2"
## [13,] "B"
                    "349.858653846154"
                                         "391.1"
                                                    "3.5"
                                                              "396.9"
## [14,] "LSTAT"
                    "13.4773076923077"
                                         "12.085"
                                                    "1.98"
                                                               "30.81"
                                                               "50"
## [15,] "MEDV"
                                         "20.4"
                                                    "6.3"
                    "21.4903846153846"
```


Construye un modelo lineal para predecir MEDV en términos de las otras variables. Utiliza descenso en gradiente para estimar los coeficientes con los predictores estandarizados.

```
#Estandarizar
std_entrena <- data.frame(matrix(unlist(lapply(1:14, function(i){(Base_entrena[,i]-mean(Base_entrena[,i
names(std_entrena) <- c("CRIM", "ZN", "INDUS", "CHAS", "NOX", "RM", "AGE", "DIS", "RAD", "TAX", "PTRATI</pre>
X
        <- as.matrix(cbind(rep(1,400), std_entrena[,1:13]))</pre>
Y
        <- as.matrix(std_entrena[,14])
RSS
        <- function(beta){
  1/2*sum((Y-X%*%beta)^2)
gradRSS <- function(beta){</pre>
  t(X) % * % (X % * % beta - Y)
OptimBeta <- function(fun, grad, X, Y, beta, eta, maxiter, tol, fprint=FALSE){
  iter
          <- 0
  toler
          <- Inf
  funval <- Inf
  while (iter<maxiter & toler > tol ) {
    beta0
               <- beta
    funvalNew <- eval(fun(beta))</pre>
              <- beta - eta*eval(grad(beta))</pre>
    toler
              <- abs(funvalNew-funval)
              <- funvalNew
    funval
    if(fprint){print(paste("Value of function",funval))}
               <- iter+1
    iter
  }
  if(iter==maxiter){
    flag <- "Did not converge"
  }else{
    flag <- paste("Converged in", iter, "steps")</pre>
  }
```

Verifica tus resultados con la función lm.

```
lmHousing <- lm(MEDV~.,data = std_entrena)</pre>
Diferencia <- formatC(t(lmHousing$coefficients-sol[[2]]), digits = 4,format = "f")
print(Diferencia)
       rep(1, 400) CRIM
                              ZN
                                       INDUS
                                                CHAS
                                                          NOX
## [1,] "-0.0000" "-0.0061" "0.0012" "0.0022" "-0.0004" "0.0005" "-0.0000"
                                             PTRATIO
                DIS
                           RAD
                                    TAX
                                                      В
## [1,] "0.0002" "-0.0002" "0.0095" "-0.0055" "-0.0003" "-0.0002" "0.0009"
ggplot()+
  geom_point(aes(lmHousing$coefficients,sol[[2]]))+
  geom_line(aes(seq(-.5,.5, length.out = 100), seq(-.5,.5, length.out = 100)))+
  theme_bw()+
  xlab("Lm")+ylab("Gradiente")+
  ggtitle("Comparar coeficientes de modelo lm contra descenso de gradiente")
```





Evalúa el error de entrenamiento y evalúa después la estimación del error de predicción Utiliza la raíz del la media de los errores al cuadrado.